

SOCIAL NETWORK ANALYSIS

Analisis Jejaring Sosial MOOC
Model Interaksi, Sentralitas Aktor, dan
Simulasi Difusi Informasi



Disusun oleh Fayyadh Fadhlurrohman

KATA PENGANTAR

Buku digital ini merupakan wujud syukur penulis atas rampungnya sebuah laporan komprehensif dari proyek praktik Social Network Analysis (SNA) yang dikerjakan menggunakan bahasa pemrograman Python beserta pustaka NetworkX. Berawal dari tugas latihan sederhana tentang jejaring pertemanan, kegiatan ini kemudian berkembang menjadi studi kasus yang jauh lebih menantang, yaitu memetakan pola interaksi puluhan ribu pengguna pada sebuah platform Massive Open Online Course (MOOC).

ACT-MOOC, dataset yang menjadi bahan kajian, diperoleh dari Stanford Network Analysis Project (SNAP) dan diperkenalkan oleh Kumar, Zhang, & Leskovec (2019) sebagai bagian dari studi jaringan interaksi temporal (JODIE); dataset ini mencatat jutaan aksi (action) yang dilakukan pengguna terhadap beragam target aktivitas pembelajaran daring. Melalui representasi graf berarah, penelusuran dalam buku ini mengungkap bagaimana ribuan simpul (node) dan ratusan ribu sisi (edge) menyusun sebuah struktur jejaring yang padat, dengan pola keterhubungan yang tidak merata serta menyimpan sejumlah aktor sentral yang memegang peran besar dalam arus interaksi di dalamnya.

Lima persoalan pokok dalam analisis jejaring dibahas secara berurutan pada buku ini: representasi graf dan matriks adjacency, pengukuran sentralitas aktor, karakteristik struktural global beserta deteksi komunitas, simulasi penyebaran

informasi, hingga visualisasi jejaring secara menyeluruh. Tiap bab dilengkapi dasar teori, potongan kode implementasi berbasis NetworkX, dan interpretasi atas hasil perhitungan aktual dari dataset yang dianalisis.

Penulis menyadari karya ini masih menyimpan banyak kekurangan sehingga kritik dan saran yang membangun senantiasa dinantikan demi penyempurnaannya di masa mendatang. Semoga tulisan ini dapat berguna sebagai referensi praktis bagi siapa pun yang berminat mempelajari analisis jejaring sosial, khususnya dalam konteks data pembelajaran daring.

Sebagai penutup, selamat membaca serta selamat menyelami struktur tersembunyi di balik jutaan interaksi digital yang tersaji dalam analisis ini.

Penulis,
Fayyadh Fadhlurrohman

DAFTAR ISI

KATA PENGANTAR.....	2
DAFTAR ISI.....	4
BAB 1 Pengantar dan Model Graf Jejaring.....	6
1.1 Representasi Graf dan Karakteristiknya	6
1.2 Jenis Graf yang Digunakan	8
1.3 Contoh Matriks Adjacency	9
BAB 2 Analisis Sentralitas Aktor Utama.....	12
2.1 Konsep dan Perhitungan Centrality	13
2.1.1 Degree Centrality	13
2.1.2 Betweenness Centrality	14
2.1.3 Closeness Centrality	16
2.1.4 Eigenvector Centrality	17
2.2 Interpretasi Node dengan Nilai Tertinggi	18
BAB 3 Karakteristik Global dan Deteksi Komunitas	21
3.1 Density, Diameter, dan Average Path Length	21
3.1.1 Density (Kerapatan Jejaring).....	21
3.1.2 Diameter dan Konektivitas Jejaring	22
3.1.3 Average Path Length	24
3.2 Analisis Koefisien Pengelompokan (Clustering Coefficient)	25
3.3 Deteksi Komunitas dengan Algoritma Louvain	28
3.3.1 Prinsip Kerja Algoritma Louvain.....	28
3.3.2 Hasil dan Interpretasi Komunitas	29

BAB 4 Simulasi Penyebaran Informasi dan Visualisasi...	33
4.1 Simulasi Propagasi Informasi / Model Epidemi	
Sederhana	33
4.1.1 Model SI (Susceptible-Infected)	33
4.1.2 Hasil Simulasi	36
4.2 Pengaruh Node Sentral terhadap Kecepatan	
Penyebaran.....	38
4.3 Visualisasi Jejaring.....	41
4.3.1 Implementasi NetworkX Spring Layout	41
4.3.2 Analisis Visual Hasil Visualisasi	43
BAB 5 Kesimpulan dan Tautan Proyek.....	45
5.1 Kesimpulan Karakteristik Jaringan	45
A. Representasi dan Jenis Graf.....	45
B. Struktur Sentralitas dan Aktor Kunci.....	45
C. Karakteristik Jarak-Pendek pada Graf Bipartit ...	46
D. Struktur Komunitas Modular	47
E. Implikasi Simulasi Difusi Informasi	47
5.2 Tautan Repository GitHub	49
DAFTAR PUSTAKA.....	51

BAB 1

Pengantar dan Model Graf Jejaring

Menerjemahkan data interaksi mentah menjadi struktur graf yang terhitung secara matematis adalah langkah paling mendasar dalam analisis jejaring sosial (Social Network Analysis/SNA). Pembahasan pada bab ini mencakup bagaimana log aktivitas pengguna pada dataset ACT-MOOC direpresentasikan sebagai graf, jenis graf yang terbentuk darinya, serta cara struktur tersebut dituangkan ke dalam bentuk matriks adjacency.

1.1 Representasi Graf dan Karakteristiknya

Secara formal, sebuah graf G dituliskan sebagai pasangan $G = (V, E)$: V merupakan himpunan node (simpul), sedangkan E merupakan himpunan edge (sisi) yang menghubungkan pasangan node tersebut. Pada dataset ACT-MOOC, satu baris data mewakili satu aksi (action) yang dilakukan seorang pengguna terhadap suatu target aktivitas pembelajaran, sehingga dua kolom yang relevan diambil sebagai pasangan (source, target) untuk membentuk edge, sebagaimana tampak pada implementasi kode berikut.

```
df = pd.read_csv(dataset_path, sep="\t", header=None,
skiprows=1)

# skiprows=1 membuang baris header yang semula ikut terbaca
sebagai data
# Kolom 1 = USERID, Kolom 2 = TARGETID
df["USERID"] = "U_" + df["USERID"].astype(str)
df["TARGETID"] = "T_" + df["TARGETID"].astype(str)
```

```
# Prefiks U_/T_ mencegah NetworkX menyatukan ID pengguna dan
# ID target yang kebetulan bernilai sama
G = nx.from_pandas_edgelist(
    df, source="USERID", target="TARGETID",
    create_using=nx.DiGraph()
)
```

Proses pembacaan dan pembentukan graf tersebut menghasilkan sebuah jejaring berskala menengah-besar, dengan karakteristik kuantitatif sebagai berikut:

Karakteristik	Nilai
Jumlah Node ($ V $)	7.144
Jumlah Edge ($ E $)	178.443
Rata-rata Edge per Node	$\approx 24,98$

Rasio jumlah edge terhadap jumlah node yang mendekati 25:1 ini mengindikasikan adanya sejumlah kecil node yakni 97 target aktivitas yang menerima interaksi dalam jumlah sangat besar dari ribuan pengguna. Pola ini merupakan konsekuensi struktural langsung dari sifat bipartit jejaring (7.047 pengguna berbagi hanya 97 target aktivitas), dan akan diperlihatkan lebih jauh melalui analisis sentralitas pada Bab 2.

Perlu digarisbawahi bahwa ACT-MOOC pada dasarnya adalah jejaring temporal: setiap aksi memiliki stempel waktu (timestamp) dan dataset ini secara eksplisit dirancang oleh Kumar, Zhang, & Leskovec (2019) untuk studi trajektori dinamis pada jejaring interaksi. Analisis pada naskah ini mengagregasi seluruh aksi menjadi satu graf statis tunggal tanpa memanfaatkan informasi waktu tersebut; akibatnya, dua

pengguna yang mengakses target aktivitas yang sama pada periode yang jauh berbeda diperlakukan setara dengan dua pengguna yang mengaksesnya secara bersamaan. Pilihan ini menyederhanakan analisis namun berpotensi mengaburkan pola dinamis (mis. urutan atau kecepatan interaksi) yang justru menjadi nilai utama dataset ini; analisis pada graf temporal atau time-sliced direkomendasikan sebagai pengembangan lanjutan.

1.2 Jenis Graf yang Digunakan

Dua karakteristik utama menentukan seluruh metode analisis pada bab-bab berikutnya, mengingat cara graf jejaring MOOC ini dibentuk:

- **Berarah (Directed Graph).** Graf dibangun menggunakan `nx.DiGraph()` karena setiap aksi memiliki arah yang jelas: dari pengguna (source) menuju target aktivitas (target). Relasi “pengguna mengakses aktivitas” bersifat tidak simetris; bukan berarti aktivitas tersebut turut “mengakses balik” penggunaanya. Sifat berarah semacam ini penting dipertahankan sejak tahap awal karena berpengaruh langsung terhadap interpretasi in-degree dan out-degree tiap node. Perlu dicatat bahwa naskah ini tidak menyajikan perhitungan atau analisis in-degree/out-degree secara terpisah pada bab-bab berikutnya — seluruh metrik pada Bab 2–4 dihitung setelah graf dikonversi menjadi tidak berarah; analisis in-degree/out-degree terpisah (mis. untuk membedakan peran pengguna sebagai pemberi aksi dan target sebagai

penerima aksi) direkomendasikan sebagai pengembangan lanjutan.

- **Tidak Berbobot (Unweighted Graph).** Bobot setiap edge dianggap seragam (bernilai 1) karena konstruksi graf melalui ``nx.from_pandas_edgelist()`` ke ``DiGraph`` (yang tidak mendukung multi-edge) secara otomatis menggabungkan seluruh pengulangan interaksi pada pasangan (user, target) yang sama menjadi satu edge tunggal; frekuensi interaksi tersebut sesungguhnya tersedia pada data mentah (yang mencatat setiap aksi sebagai baris terpisah) namun tidak dipertahankan pada tahap pembentukan graf ini. Sebagai konsekuensinya, metrik seperti density dan centrality dihitung semata berdasarkan ada-tidaknya koneksi, bukan berdasarkan intensitasnya; mempertahankan frekuensi sebagai bobot edge (weighted graph) merupakan alternatif pemodelan yang dapat dieksplorasi pada penelitian lanjutan.

Beberapa metrik struktural clustering coefficient, diameter, hingga deteksi komunitas Louvain hanya dapat dihitung pada relasi yang simetris, sehingga graf berarah lebih dulu dikonversi menjadi graf tidak berarah (undirected) melalui `G.to_undirected()` sebelum metrik-metrik tersebut diterapkan.

$$A_{\text{undirected}} = A_{\text{directed}} \vee A_{\text{directed}}^T$$

1.3 Contoh Matriks Adjacency

Representasi tabular sebuah graf dapat dituliskan sebagai matriks biadjacency B berukuran $|U| \times |T|$, dengan

elemen $B(i,j)$ bernilai 1 apabila pengguna i pernah mengakses target aktivitas j , dan bernilai 0 jika sebaliknya. Karena graf ACT-MOOC yang telah diverifikasi bersifat bipartit murni (7.047 pengguna dan 97 target aktivitas), matriks penuhnya berukuran 7.047×97 tidak dapat disajikan secara utuh dalam media cetak. Sebagai gambaran konsep, berikut ditampilkan contoh matriks biadjacency berukuran 5×5 yang menggambarkan pola akses lima pengguna ilustratif terhadap lima target aktivitas dengan Degree Centrality tertinggi dalam jejaring (T_1, T_3, T_4, T_7, dan T_8).

Dari \ Ke	T_1	T_3	T_4	T_7	T_8
User Ilustratif 1	1	0	1	0	1
User Ilustratif 2	1	1	0	1	0
User Ilustratif 3	0	1	1	0	1
User Ilustratif 4	1	0	0	1	0
User Ilustratif 5	0	1	1	0	0

Tabel 1.1 Contoh ilustrasi matriks adjacency 5×5 pada subgraf lima node dengan Degree Centrality tertinggi. Nilai 1 menandakan keberadaan edge terarah baris→kolom; matriks bersifat asimetris karena sifat graf yang berarah.

Sebagai catatan, matriks di atas hanya bersifat ilustratif untuk menjelaskan konsep matriks biadjacency dan tidak mewakili nilai eksak dari keseluruhan 178.443 edge (pasangan

unik pengguna-target) pada jejaring yang sesungguhnya. Berbeda dari matriks adjacency pada graf satu-mode, matriks biadjacency B tidak berbentuk persegi ($|U| \neq |T|$) dan tidak memiliki blok pengguna-pengguna atau target-target, karena struktur bipartit murni hanya mengizinkan edge lintas himpunan. Dalam praktiknya, NetworkX menyimpan dan memproses graf berskala penuh secara implisit dalam bentuk struktur data sparse (adjacency list/dictionary-of-dictionaries) dan bukan matriks padat, mengingat density jejaring yang sangat rendah (dibahas pada Bab 3) membuat representasi matriks penuh sangat tidak efisien dari segi memori.

BAB 2

Analisis Sentralitas Aktor Utama

Kelompok metrik dalam SNA yang mengukur seberapa penting atau sentral posisi sebuah node dalam jejaring dikenal dengan istilah sentralitas (centrality). Metrik ini melampaui sekadar penghitungan jumlah koneksi, karena melaluinya dapat diidentifikasi aktor-aktor yang memegang peran struktural krusial baik sebagai hub dengan koneksi terbanyak, sebagai jembatan penghubung kelompok yang terisolasi, maupun sebagai node yang paling mudah dijangkau dari seluruh bagian jejaring. Empat metrik sentralitas utama dihitung dan diinterpretasikan pada bab ini untuk jejaring MOOC.

Pendekatan pengukuran sentralitas semacam ini telah diterapkan pada berbagai konteks jejaring sosial lain, termasuk analisis centrality pada platform Twitter (Susanto, Lina, & Chrismanto, 2012). Lebih spesifik pada konteks MOOC, Wu & Wu (2021) menerapkan Exponential Random Graph Models untuk menelusuri mekanisme difusi pengetahuan pada forum diskusi MOOC di Coursera, menemukan bahwa pengguna berderajat sentralitas tinggi berperan aktif mentransfer pengetahuan kepada pengguna lain. Studi SNA pada MOOC lain turut memperkaya konteks ini: Zou, Hu, Pan, Li, Cai, & Liu (2021) meneliti hubungan antara social presence dan prestise pengguna pada forum diskusi MOOC, sementara Soleymani, Itard, de Laat, Valle Torre, & Specht (2022) menganalisis karakteristik jejaring pembelajaran pada forum diskusi tiga MOOC berbeda; kedua studi ini, sebagaimana naskah ini,

memanfaatkan metrik sentralitas untuk mengidentifikasi pengguna berpengaruh dalam konteks pembelajaran daring berskala besar. Namun demikian, temuan meta-analisis skala besar oleh Saqr & Lopez-Pernas (2022) serta Saqr, Elmoazen, Tedre, Lopez-Pernas, & Hirsto (2022) pada konteks pembelajaran kolaboratif berbasis komputer menunjukkan bahwa daya prediksi metrik sentralitas terhadap capaian belajar sangat bervariasi antarstudi dan bergantung besar pada konteks jejaring yang dianalisis sebuah catatan kehati-hatian yang relevan diperhatikan pula pada interpretasi sentralitas dalam naskah ini (Subbab 2.2).

2.1 Konsep dan Perhitungan Centrality

2.1.1 Degree Centrality

Di antara keempat metrik sentralitas, Degree Centrality adalah yang paling intuitif untuk dipahami: posisi sebuah node akan semakin sentral seiring bertambahnya jumlah koneksi langsung yang dimilikinya. Pada graf tak berarah, degree suatu node v didefinisikan sebagai banyaknya edge yang terhubung kepadanya, dengan rumus normalisasi sebagai berikut:

$$C_D(v) = \frac{\deg(v)}{N - 1}$$

N merupakan jumlah total node dalam graf. Melalui normalisasi ($N-1$), nilai Degree Centrality dibatasi pada rentang $[0, 1]$ dan menjadi independen terhadap ukuran jejaring, sehingga perbandingan antargraf berskala berbeda tetap dapat

dilakukan. NetworkX menghitung metrik ini dengan baris kode berikut:

```
degree_cent = nx.degree_centrality(G)
top_5_degree = sorted(
    degree_cent.items(), key=lambda x: x[1], reverse=True
)[:5]
```

Hasil perhitungan pada jejaring MOOC menghasilkan Top 5 node berdasarkan Degree Centrality:

Peringkat	Node	Degree Centrality
1	T_1	0.9373
2	T_3	0.8622
3	T_4	0.7810
4	T_7	0.7290
5	T_8	0.7021

Tabel 2.1 Top 5 Node berdasarkan Degree Centrality pada jejaring MOOC.

2.1.2 Betweenness Centrality

Betweenness Centrality menghitung seberapa sering sebuah node dilalui jalur terpendek (shortest path) yang menghubungkan dua node lain dalam jejaring. Ketika node dengan nilai tinggi pada metrik ini dihapus, banyak jalur komunikasi antarpasangan node lain akan terputus atau memanjang — karena itulah node semacam ini disebut berperan sebagai jembatan atau broker informasi. Rumus yang digunakan adalah:

$$C_B(v) = \sum_{s \neq v \neq t} \frac{\sigma(s, t|v)}{\sigma(s, t)}$$

$\sigma(s, t)$ menyatakan jumlah total shortest path dari s ke t , sedangkan $\sigma(s, t|v)$ menyatakan jumlah shortest path yang melewati node v . Sebab kompleksitas waktu perhitungan eksak Betweenness Centrality mencapai $O(VE)$ cukup besar untuk jejaring berskala 7.144 node dan 178.443 edge pendekatan aproksimasi berbasis sampling ($k=500$ node sampel) digunakan sebagai praktik standar dalam analisis graf berskala besar:

Hasil aproksimasi ini menggunakan satu nilai seed (seed=42) tanpa pengujian sensitivitas terhadap seed atau nilai k lain; kestabilan peringkat Top-5 pada Tabel 2.2 terhadap variasi seed belum diverifikasi dan menjadi salah satu keterbatasan metodologis penelitian ini.

```
betweenness = nx.betweenness_centrality(
    G_undirected, k=500, seed=42
)
```

Hasil Top 5 Betweenness Centrality:

Peringkat	Node	Betweenness Centrality
1	T_1	0.1672
2	T_3	0.1163
3	T_4	0.0757
4	T_8	0.0625
5	T_7	0.0583

Tabel 2.2 Top 5 Node berdasarkan Betweenness Centrality (aproksimasi $k=500$).

2.1.3 Closeness Centrality

Closeness Centrality menangkap seberapa dekat, secara rata-rata, posisi sebuah node terhadap seluruh node lain dalam jejaring. Node dengan nilai tinggi pada metrik ini mampu menyebarkan informasi ke seluruh jaringan dalam waktu tersingkat. Normalisasi Wasserman-Faust dipilih sebagai rumus perhitungan karena tetap berfungsi baik pada jejaring yang tidak sepenuhnya terhubung (disconnected):

$$C_c(v) = \frac{n-1}{N-1} \cdot \frac{n-1}{\sum_{u \neq v} d(v,u)}$$

n menyatakan jumlah node yang terjangkau dari v , $d(v,u)$ menyatakan jarak terpendek antara v dan u , sementara N menyatakan total node. Berbeda dari versi analisis sebelumnya, jejaring MOOC yang telah dikoreksi kini terhubung penuh (fully connected, 7.144 node), sehingga Closeness Centrality dapat dihitung langsung pada graf lengkap tanpa perlu membatasi perhitungan pada giant component:

```
closeness = nx.closeness_centrality(G_undirected)
top_5_close = sorted(
    closeness.items(), key=lambda x: x[1], reverse=True
)[:5]
```

Hasil Top 5 Closeness Centrality:

Peringkat	Node	Closeness Centrality
1	T_1	0.8993
2	T_3	0.7923

3	T_4	0.7020
4	T_7	0.6542
5	T_8	0.6320

Tabel 2.3 Top 5 Node berdasarkan Closeness Centrality pada jejaring MOOC (graf penuh, terhubung).

2.1.4 Eigenvector Centrality

Eigenvector Centrality merupakan metrik paling canggih di antara keempat metrik sentralitas yang dibahas. Bila Degree Centrality hanya menghitung banyaknya koneksi, metrik ini turut memperhitungkan kualitas koneksi tersebut: keterhubungan dengan node-node penting akan meningkatkan skor sentralitas sebuah node secara proporsional. Skor Eigenvector Centrality $x(v)$ secara matematis memenuhi persamaan nilai eigen (eigenvalue equation) berikut:

$$\lambda \cdot x(v) = \sum_{u \in N(v)} x(u)$$

λ menyatakan eigenvalue terbesar dari matriks adjacency A , dan NetworkX menyelesaikan persamaan tersebut melalui dekomposisi nilai eigen numerik (numpy). Karena jejaring MOOC yang telah dikoreksi kini terhubung penuh, perhitungan dapat dilakukan langsung pada graf lengkap tanpa risiko ambiguitas matematis yang sebelumnya berpotensi muncul pada graf diskoneks:

```
eigenvector = nx.eigenvector_centrality_numpy(G_undirected)
top_5_eigen = sorted(
```

```
eigenvector.items(), key=lambda x: x[1], reverse=True
)[:5]
```

Hasil Top 5 Eigenvector Centrality:

Peringkat	Node	Eigenvector Centrality
1	T_1	0.1439
2	T_3	0.1385
3	T_7	0.1358
4	T_4	0.1350
5	T_5	0.1298

Tabel 2.4 Top 5 Node berdasarkan Eigenvector Centrality pada jejaring MOOC (graf penuh, terhubung).

2.2 Interpretasi Node dengan Nilai Tertinggi

Perbandingan keempat metrik sentralitas mengungkap perbedaan peran struktural yang dipegang oleh node-node berbeda dalam jejaring MOOC. Temuan ini dirangkum dalam tabel konsolidasi berikut:

Node	Degree	Betweenness	Closeness	Eigenvector	Peran Utama
T_1	0.9373 (★1)	0.1672 (★1)	0.8993 (★1)	0.1439 (★1)	Aktivitas Dominan (Top-1 di Seluruh Metrik)
T_3	0.8622 (★2)	0.1163 (★2)	0.7923 (★2)	0.1385 (★2)	Aktivitas Sangat Populer

T_4	0.7810 (★3)	0.0757 (★3)	0.7020 (★3)	0.1350 (★4)	Aktivitas Populer
T_7	0.7290 (★4)	0.0583 (★5)	0.6542 (★4)	0.1358 (★3)	Aktivitas Populer & Terhubung Baik
T_8	0.7021 (★5)	0.0625 (★4)	0.6320 (★5)	—	Aktivitas Cukup Populer
T_5	—	—	—	0.1298 (★5)	Aktivitas dengan Koneksi Berkualitas

Tabel 2.5 Konsolidasi peringkat sentralitas seluruh node unggulan pada jejaring bipartit terkoreksi (7.144 node). Tanda — berarti node tidak masuk Top 5 pada metrik tersebut. Berbeda dari versi analisis sebelumnya, keempat metrik pada tabel ini kini dihitung pada basis graf yang identik (graf terhubung penuh, 7.144 node), sehingga perbandingan langsung antarmetrik pada tabel ini bersifat setara, bukan lagi indikatif.

Dari tabel konsolidasi di atas, muncul satu pola struktural yang jelas dan konsisten di seluruh metrik:

- Seluruh Top 5 pada Keempat Metrik Sentralitas Ditempati Node TARGET, Bukan Node USER. Tidak satu pun dari 7.047 node bertipe pengguna yang masuk peringkat lima besar pada Degree, Betweenness, Closeness, maupun Eigenvector Centrality; keenam node unggulan (T_1, T_3, T_4, T_5, T_7, T_8) seluruhnya adalah target aktivitas. Pola ini bukan sinyal keistimewaan platform, melainkan konsekuensi struktural yang dapat diprediksi dari rasio populasi node yang sangat timpang (97 target berbanding 7.047

pengguna): karena tiap target berpotensi diakses oleh ribuan pengguna sementara tiap pengguna umumnya hanya mengakses segelintir target, target populer mana pun nyaris pasti akan mengungguli pengguna mana pun pada metrik sentralitas apa pun.

- T_1 sebagai Aktivitas Paling Dominan. T_1 menduduki peringkat pertama secara mutlak pada keempat metrik sekaligus Degree (0.9373), Betweenness (0.1672), Closeness (0.8993), dan Eigenvector (0.1439) menjadikannya target aktivitas yang paling banyak diakses, paling sering berada di jalur terpendek antarpengguna, dan paling dekat secara struktural terhadap keseluruhan jejaring. T_3 secara konsisten menempati posisi kedua pada seluruh metrik, mengindikasikan aktivitas ini sebagai konten paling populer setelah T_1.
- Interpretasi Tingkat Pengguna Individual Memerlukan Analisis Terpisah. Karena top-5 gabungan seluruhnya bertipe target, tabel ini tidak dapat menjawab pertanyaan siapa pengguna paling berpengaruh dalam jejaring. Menjawab pertanyaan tersebut memerlukan penyaringan (filtering) khusus terhadap node bertipe USER sebelum melakukan perankingan, atau analisis pada graf proyeksi user-user (dibahas pada Subbab 3.3); analisis tersebut belum dicakup pada bab ini dan direkomendasikan sebagai pengembangan lanjutan.

BAB 3

Karakteristik Global dan Deteksi Komunitas

Bila Bab 2 berfokus pada level node menelusuri siapa aktor yang paling penting maka Bab 3 beralih ke perspektif makro: bagaimana bentuk dan sifat jejaring MOOC secara keseluruhan? Apakah strukturnya padat atau renggang? Seberapa jauh jarak rata-rata yang memisahkan penggunanya? Serta, adakah pengelompokan alami yang mencerminkan komunitas belajar yang berbeda-beda? Keempat metrik struktural global beserta satu algoritma deteksi komunitas digunakan untuk menjawab pertanyaan-pertanyaan tersebut.

3.1 Density, Diameter, dan Average Path Length

3.1.1 Density (Kerapatan Jejaring)

Density menyatakan proporsi edge yang benar-benar terwujud dalam jejaring terhadap jumlah edge maksimum yang mungkin terbentuk. Pada graf berarah dengan N node, jumlah edge maksimum adalah $N(N-1)$, sehingga rumus density dituliskan sebagai:

$$D = \frac{|E|}{N(N-1)}$$

Untuk graf tidak berarah, penyebutnya menjadi $N(N-1)/2$. Pada jejaring MOOC yang dianalisis:

<pre>density = nx.density(G) # Hasil: 0.003497</pre>	
Parameter	Nilai

Jumlah Node (N)	7.144
Jumlah Edge (E)	178.443
Edge Maksimum Teoritis	51.029.592
Density (D)	0.003497

Tabel 3.1 Komponen perhitungan Density jejaring MOOC.

Angka Density sebesar 0,003497 (setara 0,35%) menegaskan bahwa jejaring ini tergolong sangat renggang (sparse) sebuah karakteristik yang umum dijumpai pada jejaring sosial berskala besar (Newman, 2010): dari sekitar 51 juta kemungkinan koneksi yang dapat terbentuk di antara 7.144 node, hanya sekitar 178 ribu yang benar-benar terwujud. Kerapatan serendah ini merupakan konsekuensi langsung dari struktur bipartit jejaring: karena edge hanya dapat terbentuk lintas himpunan pengguna-target (tidak ada edge pengguna-pengguna maupun target-target), ruang kemungkinan koneksi jauh lebih terbatas dibanding graf satu-mode berukuran setara, dan secara struktural menggambarkan kenyataan bahwa tiap pengguna MOOC hanya berinteraksi dengan sebagian kecil saja dari 97 target aktivitas yang tersedia di platform.

3.1.2 Diameter dan Konektivitas Jejaring

Jarak terpendek terpanjang (longest shortest path) di antara seluruh pasangan node pada jejaring yang saling terhubung didefinisikan sebagai diameter jejaring. Berbeda dari analisis versi sebelumnya, jejaring MOOC yang telah dikoreksi (dengan namespace ID terpisah) kini terbukti terhubung penuh

(fully connected) seluruh 7.144 node dapat saling dijangkau tanpa terkecuali sehingga diameter dapat dihitung langsung pada graf lengkap tanpa perlu mengisolasi giant component:

<pre># Jejaring terhubung penuh setelah koreksi namespace print(nx.is_connected(G_undirected)) # True diameter = nx.diameter(G_undirected) # Diameter: 4</pre>	
Parameter	Nilai
Status Konektivitas	Terhubung Penuh
Ukuran Jejaring (Graf Penuh Terhubung)	7.144 node (100%)
Node Terisolasi / Di Luar Komponen	0 node
Diameter (Graf Penuh)	4

Tabel 3.2 Karakteristik konektivitas dan diameter jejaring MOOC.

Temuan diameter sebesar 4 ini cukup menarik perhatian: jalur terpendek antara dua node mana pun di dalam jejaring tidak pernah melampaui 4 langkah. Dengan kata lain, dari pengguna atau aktivitas mana pun, pengguna atau aktivitas lainnya dapat dijangkau hanya dalam maksimal empat lompatan interaksi. Fenomena ini sejalan dengan properti “six degrees of separation”, hanya saja dalam versi yang jauh lebih ringkas konsekuensi logis dari keberadaan beberapa node target dengan Degree Centrality sangat tinggi (T_1: 0,9373) yang berfungsi “memadatkan” jarak antarnode, sebuah pola yang khas pada graf bipartit dengan rasio populasi timpang (97 target melayani 7.047 pengguna).

3.1.3 Average Path Length

Rata-rata seluruh jarak terpendek di antara pasangan node yang saling terjangkau disebut Average Path Length (APL), yang menggambarkan seberapa jauh dua node “acak” umumnya terpisah dalam jejaring. Mengingat perhitungan eksak APL pada jejaring berskala 7.144 node membutuhkan $O(V^2)$ operasi, digunakan pendekatan aproksimasi berbasis sampling:

```
import random
random.seed(42)
sample_nodes = random.sample(list(G_undirected.nodes()), 500)
lengths = []
for n in sample_nodes:
    sp = nx.single_source_shortest_path_length(G_undirected,
n)
    lengths.extend(sp.values())
avg_path_length = sum(lengths) / len(lengths)
# Hasil: 2.0236
```

Perhitungan ini menggunakan seed tunggal (seed=42) tanpa interval kepercayaan atau pengujian pada seed lain, sehingga variabilitas estimasi APL akibat pengambilan sampel belum dapat dikuantifikasi. Nilai APL sebesar 2,0236 menunjukkan bahwa dua node dalam jejaring, secara rata-rata, hanya terpisah oleh sekitar 2 langkah interaksi. APL rendah (2,02) berpadu dengan diameter kecil (4) merupakan konsekuensi khas graf bipartit yang didominasi segelintir node hub bertipe target: karena hampir seluruh pengguna terhubung ke sedikit target populer yang sama, jarak antarpengguna mana pun dapat ditempuh dalam sedikit lompatan melalui target tersebut sebagai perantara.

3.2 Analisis Koefisien Pengelompokan (Clustering Coefficient)

Derajat klusterisasi di sekitar sebuah node yakni seberapa besar peluang dua tetangga dari node v turut saling terhubung diukur melalui Clustering Coefficient, atau secara intuitif dapat dipahami sebagai “kepadatan segitiga” di sekitar tiap node. Untuk node v dengan $k(v)$ tetangga dan $t(v)$ edge yang benar-benar ada di antara tetangga-tetangga tersebut, Clustering Coefficient lokal dirumuskan sebagai:

$$C(v) = \frac{t(v)}{\binom{k(v)}{2}} = \frac{2 \cdot t(v)}{k(v)(k(v) - 1)}$$

Sedangkan Average Clustering Coefficient (ACC) adalah rata-rata dari $C(v)$ untuk seluruh node:

$$\langle C \rangle = \frac{1}{N} \sum_{v \in V} C(v)$$

```
G_undirected = G.to_undirected()
avg_clustering = nx.average_clustering(G_undirected)
# Hasil: 0.000000
```

```
from networkx.algorithms import bipartite
print(bipartite.is_bipartite(G_undirected)) # True
```

Metrik	Nilai	Interpretasi
Average Clustering Coefficient	0.000000	Nol (Sesuai Teori Graf Bipartit Murni)
Average Path Length	2.0236	Rendah
Diameter	4	Kecil untuk 7.144 node
Density	0.003497	Sangat Rendah (Sparse)

Tabel 3.3 Empat metrik struktural global jejaring MOOC dan interpretasinya.

Angka ACC sebesar 0,000000 pada jejaring yang telah dikoreksi ini sekarang justru menegaskan validitas struktural graf, dan memberi jawaban pasti atas anomali yang pada versi analisis sebelumnya sempat dilaporkan sebagai “inkonsistensi teoretis yang belum dijelaskan”. Pada graf dua-mode (bipartite) murni antara pengguna dan target aktivitas, edge hanya menghubungkan node lintas himpunan sehingga secara definisi tidak dapat terbentuk segitiga tunggal pun, dan Clustering Coefficient seharusnya bernilai nol untuk setiap node. Verifikasi eksplisit melalui `nx.bipartite.is_bipartite()` pada jejaring yang telah diberi namespace ID terpisah (prefiks U_ untuk pengguna, T_ untuk target) mengonfirmasi True, sejalan sempurna dengan $ACC = 0$. Akar penyebab anomali pada analisis sebelumnya ($ACC = 0,6266$) telah ditelusuri dan ditemukan: seluruh 97 TARGETID pada dataset mentah ternyata bertabrakan secara numerik dengan sebagian USERID, sehingga NetworkX menyatukan node pengguna dan node target yang kebetulan bernomor sama menjadi satu node tunggal node hasil leburan inilah yang menciptakan jalur ganda (masuk sebagai target, keluar sebagai pengguna) yang secara mekanis memungkinkan pembentukan segitiga semu. Dengan pemisahan namespace ID, jejaring kini terverifikasi sebagai bipartit murni tanpa pengecualian.

Karena ACC bernilai nol secara struktural pada graf bipartit, klasifikasi Small-World Network versi klasik (Watts & Strogatz, 1998), yang mensyaratkan clustering coefficient tinggi

berdampingan dengan average path length rendah tidak dapat diterapkan secara langsung pada jejaring ini. Kriteria clustering tinggi pada model Watts-Strogatz dirancang untuk graf satu-mode di mana segitiga bermakna secara struktural (mis. pertemanan antarpengguna); pada graf bipartit murni, clustering coefficient akan selalu bernilai nol terlepas dari seberapa “padat” jejaring tersebut secara substantif, sehingga metrik ini kehilangan daya bedanya. Yang tetap dapat dilaporkan secara sah adalah fenomena jarak pendek (short-path phenomenon): APL rendah (2,02) dan diameter kecil (4) tetap menunjukkan bahwa jejaring ini sangat “kompak” meski renggang secara global (density 0,35%) sebuah pola yang khas pada graf bipartit hub-dominan (star-like), bukan pada graf small-world klasik dalam pengertian Watts-Strogatz.

Perlu dicatat bahwa pengujian formal terhadap null model acak (mis. rasio L/L_{random} terhadap model Erdős–Rényi bipartit) belum dilakukan pada naskah ini untuk mengonfirmasi apakah $APL = 2,0236$ tergolong signifikan lebih rendah dibanding graf bipartit acak berukuran sama (7.047 pengguna, 97 target, 178.443 edge); pengujian ini direkomendasikan pada penelitian lanjutan. Pengujian rasio clustering (C/C_{random}) yang biasa menjadi bagian dari prosedur baku Watts-Strogatz tidak relevan diterapkan di sini, mengingat $C = 0$ merupakan konsekuensi struktural bipartit yang berlaku pada graf bipartit acak mana pun, bukan properti yang membedakan jejaring MOOC dari graf acak pembanding.

3.3 Deteksi Komunitas dengan Algoritma Louvain

Sesudah metrik global dipahami, langkah berikutnya adalah menelusuri apakah jejaring MOOC memiliki struktur komunitas internal yang bermakna. Karena jejaring bipartit murni tidak memiliki segitiga (Subbab 3.2), algoritma Louvain tidak dapat dijalankan secara bermakna langsung pada graf dua-mode ini; pendekatan yang digunakan adalah memproyeksikan graf bipartit ke graf satu-mode user-user terlebih dahulu (dua pengguna terhubung apabila berbagi setidaknya satu target aktivitas yang sama), baru kemudian menjalankan Louvain (Blondel et al., 2008) pada graf proyeksi tersebut. Pendekatan proyeksi ini merupakan salah satu strategi umum untuk deteksi komunitas pada graf bipartit, meskipun literatur terkini (mis. Yen & Larremore, 2020) menunjukkan bahwa proyeksi dapat menghilangkan sebagian informasi struktural dua-mode dibanding model khusus bipartit seperti stochastic block model bipartit sebuah keterbatasan metodologis yang turut relevan dengan rendahnya nilai Modularity yang dilaporkan pada Subbab 3.3.2.

3.3.1 Prinsip Kerja Algoritma Louvain

Metrik Modularity (Q) yang mengukur seberapa baik jejaring terbagi ke dalam kelompok-kelompok berkoneksi internal lebih padat dibanding yang diharapkan secara acak dioptimalkan oleh algoritma Louvain (Blondel et al., 2008) melalui rumus berikut:

$$Q = \frac{1}{2m} \sum_{i,j} \left[A_{ij} - \frac{k_i k_j}{2m} \right] \delta(c_i, c_j)$$

dengan m adalah jumlah edge, $A(ij)$ adalah elemen matriks adjacency, $k(i)$ dan $k(j)$ adalah degree node i dan j , serta $\delta(c_i, c_j)$ bernilai 1 jika i dan j berada di komunitas yang sama. Algoritma bekerja dalam dua fase yang diulang secara iteratif: (1) fase alokasi node ke komunitas lokal terbaik, dan (2) fase agregasi untuk membangun jejaring level baru dari komunitas-komunitas tersebut.

```
from networkx.algorithms import bipartite
import community as community_louvain

# Louvain pada graf bipartit mentah tidak bermakna
# (tidak ada segitiga untuk dioptimalkan)
# -> proyeksikan dulu ke graf user-user
user_projection = bipartite.weighted_projected_graph(
    G_bipartite, user_nodes
)
partition = community_louvain.best_partition(
    user_projection, random_state=42
)
modularity_q = community_louvain.modularity(
    partition, user_projection
)
# Hasil: 3 komunitas, Modularity (Q) = 0.0865
```

3.3.2 Hasil dan Interpretasi Komunitas

Algoritma Louvain, dijalankan pada graf proyeksi user-user (7.047 node, 24.668.085 edge) dengan `random_state=42` untuk menjamin reproduksibilitas, berhasil mengidentifikasi 3 komunitas pada populasi pengguna jejaring MOOC. Modularity (Q) yang dihasilkan sebesar 0,0865 tergolong rendah secara umum, nilai Q di atas $\sim 0,3$ dianggap menunjukkan struktur

komunitas yang bermakna secara statistik, sehingga partisi 3 komunitas ini perlu diinterpretasikan dengan kehati-hatian sebagai struktur yang lemah, bukan pengelompokan yang solid. Distribusi ukuran komunitas juga sangat timpang (4.471, 2.520, dan hanya 56 user), berbeda jauh dari distribusi yang relatif merata pada laporan sebelumnya. Penyebab paling mungkin dari lemahnya struktur ini adalah karakteristik graf proyeksi itu sendiri: dengan hanya 97 target aktivitas yang dibagi ke 7.047 pengguna, kemungkinan dua pengguna mana pun berbagi setidaknya satu target yang sama sangat tinggi, membuat graf proyeksi nyaris menjadi graf lengkap (densitas $\sim 99,3\%$, dari maksimum teoretis 24.830.881 edge). Pada graf yang nyaris lengkap semacam ini, algoritma modularitas memang secara inheren kesulitan menemukan partisi yang jelas, karena hampir semua pasangan node sama-sama saling terhubung.

Komunitas	Jumlah User (Eksak)	Persentase	Catatan
Komunitas 0	4.471 user	63,5%	Kelompok mayoritas
Komunitas 2	2.520 user	35,8%	Kelompok kedua terbesar
Komunitas 1	56 user	0,8%	Kelompok sangat kecil; kemungkinan artefak partisi pada graf proyeksi yang nyaris lengkap (densitas $\sim 99\%$)

Tabel 3.4 Tiga komunitas yang terdeteksi oleh algoritma Louvain pada graf proyeksi user-user, dengan jumlah anggota dihitung secara eksak melalui Counter(partition.values()), bukan estimasi visual. Modularity $Q = 0,0865$ tergolong rendah, sehingga pembagian ini sebaiknya dibaca sebagai struktur komunitas yang lemah, bukan pengelompokan yang kuat dan tegas.

Mengingat Modularity $Q = 0,0865$ tergolong rendah dan distribusi ukuran komunitas sangat timpang (satu di antaranya hanya beranggotakan 56 dari 7.047 pengguna), naskah ini tidak lagi menyajikan interpretasi kontekstual yang kaya atas makna ketiga komunitas tersebut (mis. sebagai “modul wajib” atau “jalur belajar berbeda”) seperti pada versi analisis sebelumnya. Interpretasi semacam itu memerlukan struktur komunitas yang jauh lebih tegas untuk dapat dipertanggungjawabkan secara metodologis. Yang dapat dilaporkan secara sah dari temuan ini adalah bahwa, pada level pengguna, jejaring MOOC tidak menunjukkan struktur pengelompokan yang kuat, kemungkinan besar karena keterbatasan jumlah target aktivitas (97) yang menyebabkan tingkat overlap keanggotaan antarpengguna terlalu tinggi untuk menghasilkan pemisahan modular yang jelas.

Perlu ditegaskan pula bahwa dataset ACT-MOOC yang dianalisis (Subbab 5.2) hanya berisi pasangan ID pengguna, ID target aktivitas, dan aksi, tanpa metadata nama aktivitas, kategori kurikulum, atau label modul. Sekalipun struktur komunitas yang terdeteksi kelak terbukti lebih kuat pada revisi berikutnya (mis. melalui pemberian ambang bobot pada graf proyeksi), interpretasi konten spesifik apa pun terhadap tiap komunitas tetap memerlukan data tambahan berupa metadata

kurikulum dari penyelenggara platform, karena tidak dapat diverifikasi langsung dari variabel yang tersedia dalam dataset saat ini. Kehati-hatian semacam ini sejalan dengan rekomendasi metodologis Poquet, Saqr, & Chen (2021) bagi riset jejaring pada learning analytics, yang menekankan bahwa temuan struktural (mis. komunitas, sentralitas) perlu diinterpretasikan bersama konteks pedagogis yang memadai, bukan dibaca murni dari topologi graf semata.

- Implikasi Pedagogis (Bersifat Tentatif): Mengingat lemahnya struktur komunitas yang terdeteksi ($Q = 0,0865$), rekomendasi konten personal berbasis keanggotaan komunitas belum dapat diusulkan secara meyakinkan pada tahap analisis ini. Eksplorasi lanjutan misalnya dengan menerapkan ambang bobot minimum pada graf proyeksi (hanya mempertahankan pasangan pengguna yang berbagi lebih dari satu target) diperlukan lebih dahulu untuk menghasilkan struktur komunitas yang cukup tegas sebelum implikasi pedagogis semacam ini dapat diajukan dengan percaya diri.
- Implikasi Teknis (Bersifat Tentatif): Demikian pula, pemanfaatan struktur komunitas untuk kebijakan partisi server atau caching konten sebaiknya ditunda hingga tersedia partisi dengan Modularity yang lebih meyakinkan. Rekomendasi caching berbasis akses bersama tetap dapat dipertimbangkan, namun idealnya didasarkan langsung pada pasangan target aktivitas yang paling sering diakses bersama (co-access pattern pada level target, bukan level komunitas pengguna yang saat ini masih lemah).

BAB 4

Simulasi Penyebaran Informasi dan Visualisasi

Pertanyaan yang relevan secara praktis muncul setelah struktur dan komunitas jejaring dipahami: bagaimana informasi bergerak di dalamnya? Studi serupa mengenai penyebaran informasi melalui pendekatan SNA telah dilakukan pada konteks lain, misalnya diseminasi country branding (Setatama & Tricahyono, 2017). Node mana yang paling strategis untuk dijadikan titik injeksi informasi? Dan bagaimana pemilihan titik awal yang berbeda memengaruhi kecepatan jangkauan informasi ke seluruh jejaring? Simulasi penyebaran informasi berbasis model epidemi digunakan pada bab ini untuk menjawab pertanyaan-pertanyaan tersebut, dilanjutkan dengan visualisasi komprehensif dari keseluruhan analisis.

4.1 Simulasi Propagasi Informasi / Model Epidemi Sederhana

4.1.1 Model SI (Susceptible-Infected)

Model epidemi paling sederhana yang relevan langsung untuk mensimulasikan penyebaran informasi pada jejaring adalah model SI (Susceptible-Infected), yang penerapannya pada jejaring kompleks banyak dibahas dalam literatur epidemi jejaring seperti Pastor-Satorras & Vespignani (2001), dan membagi setiap node ke dalam salah satu dari dua kondisi berikut:

- **Susceptible (S):** Node yang belum menerima informasi dan berpotensi tertular dari tetangganya yang telah terinfeksi.
- **Infected (I):** Node yang telah menerima serta membawa informasi, dan dapat menyebarkannya lebih jauh kepada tetangga yang masih berstatus Susceptible.

Pada tiap langkah waktu (time step), setiap edge (u, v) dengan u berstatus Infected dan v berstatus Susceptible memiliki probabilitas β untuk mengalami transmisi informasi. Karena model SI tidak mengenal mekanisme “sembuh” (recovery), informasi akan terus menyebar hingga seluruh node terjangkau — menjadikannya model yang tepat untuk merepresentasikan penyebaran berita atau konten viral yang, begitu diterima, tidak lagi bisa “dilupakan”.

Simulasi pada bab ini juga hanya diuji pada satu nilai probabilitas transmisi ($\beta=0.1$); analisis sensitivitas terhadap variasi β — parameter yang paling menentukan laju penyebaran pada model epidemi — belum dilakukan dan disarankan sebagai pengembangan lebih lanjut.

$$\frac{dI}{dt} = \beta \cdot S(t) \cdot I(t)$$

Implementasi simulasi SI dijalankan pada graf bipartit yang telah terkoreksi (kini terhubung penuh, sehingga tidak lagi memerlukan pembatasan pada giant component). Perlu digarisbawahi satu perubahan konseptual penting: karena seluruh node top-5 sentralitas kini terbukti bertipe TARGET (Subbab 2.2), bukan USER, titik injeksi simulasi pada bab ini

direinterpretasi sebagai eksposur terhadap sebuah konten/aktivitas (content-exposure diffusion), bukan sebagai pengguna individual yang menyebarkan informasi ke pengguna lain (person-to-person diffusion) seperti kerangka pada versi analisis sebelumnya. Simulasi tetap berjalan pada mekanisme graf yang sama menyebarkan status “terinfeksi” melalui edge namun titik awal T_1, T_3, atau T_8 kini dipahami sebagai “berapa cepat eksposur terhadap aktivitas ini menjalar ke seluruh populasi pengguna dan target lain”, sebuah kerangka yang secara konseptual lebih sesuai dengan sifat bipartit jejaring dibanding asumsi lama.

```
import random

def simulate_SI(G, seed_node, beta=0.1, steps=10):
    infected = {seed_node}
    susceptible = set(G.nodes()) - infected
    history = [len(infected)]
    for _ in range(steps):
        new_infected = set()
        for node in list(infected):
            for neighbor in G.neighbors(node):
                if neighbor in susceptible:
                    if random.random() < beta:
                        new_infected.add(neighbor)
        infected |= new_infected
        susceptible -= new_infected
        history.append(len(infected))
    return history

# Titik injeksi bertipe TARGET (content-exposure diffusion)
random.seed(42); hist_T1 = simulate_SI(G_undirected, "T_1",
beta=0.1, steps=10)
random.seed(42); hist_T3 = simulate_SI(G_undirected, "T_3",
beta=0.1, steps=10)
random.seed(42); hist_T8 = simulate_SI(G_undirected, "T_8",
beta=0.1, steps=10)
# Hasil: lihat Tabel 4.1 (T_1/T_3 unggul di t<=2,
```

seluruh titik konvergen >99% pada t=10)

4.1.2 Hasil Simulasi

Guna membandingkan kecepatan penyebaran, simulasi dijalankan sebanyak tiga kali dengan titik injeksi berbeda dari kalangan node target: T_1 (peringkat 1 pada seluruh metrik sentralitas), T_3 (peringkat 2 pada seluruh metrik), dan T_8 (peringkat lebih rendah, sebagai pembanding), dengan probabilitas transmisi $\beta = 0,1$ yang berlaku seragam pada seluruh skenario. Sebagai perbandingan historis, versi analisis sebelumnya (yang memakai Node 1, Node 22, dan Node 999) dihasilkan dari graf yang telah terbukti cacat struktural (Subbab 3.2, Subbab 5.2) sehingga tidak dapat dipertahankan; simulasi telah dijalankan ulang secara utuh pada graf terkoreksi, dan angka-angka pada Tabel 4.1 serta 4.2 berikut merupakan hasil simulasi ulang tersebut.

Perlu dicatat bahwa dengan reinterpretasi content-exposure di atas, kekhawatiran metodologis pada versi sebelumnya perihal “memperlakukan target sebagai agen penyebar aktif setara pengguna” kini tidak lagi relevan: simulasi tidak lagi diklaim merepresentasikan pengguna yang secara aktif menyebarkan informasi ke pengguna lain, melainkan murni memodelkan laju perambatan eksposur melalui struktur graf bipartit sejalan dengan kerangka diseminasi konten (Setatama & Tricahyono, 2017) yang dirujuk pada awal bab ini.

Time Step	T_1	T_3	T_8
-----------	-----	-----	-----

t=0	1	1	1
t=1	648	600	482
t=2	1357	1265	1017
t=3	5800	5798	5655
t=5	6816	6789	6761
t=7	7039	7025	7028
t=10	7112	7116	7108

Tabel 4.1 Jumlah node ter-eksposur per time step dari tiga titik injeksi target (T_1, T_3, T_8) pada graf terkoreksi ($\beta=0,1$, 10 langkah, seed direset ke 42 pada tiap simulasi agar ketiganya independen dan reproducible).

Hasil simulasi menunjukkan pola sebagai berikut:

- T_1 menunjukkan laju eksposur tercepat pada tahap awal simulasi: setelah 1 langkah, T_1 telah mengekspos 648 node, unggul 34,4% dibanding T_8 (482 node), dan setelah 2 langkah unggul 33,4% (1.357 berbanding 1.017 node). Keunggulan ini sejalan dengan prediksi teoretis berdasarkan dominasi T_1 pada seluruh metrik sentralitas.
- T_3 secara konsisten berada tepat di bawah T_1 pada tahap awal (600 node pada t=1, 1.265 pada t=2), sesuai posisi peringkat 2 pada seluruh metrik sentralitas menggarisbawahi keunggulan sistematis T_1 dan T_3 dibanding T_8 pada masa awal difusi.
- T_8 menunjukkan laju eksposur paling lambat pada tahap awal (482 node pada t=1; 1.017 pada t=2), sesuai prediksi karena kedudukannya sebagai anggota top-5

dengan nilai sentralitas terendah di antara T_1, T_3, T_4, T_7, dan T_8. Namun demikian, keunggulan T_1 dan T_3 ini bersifat sementara: mulai $t=3$, seluruh jejaring mengalami lonjakan eksposur serentak (5.655–5.800 node, atau sekitar 79–81% dari total jejaring, dalam satu langkah saja), dan sejak $t \geq 5$ selisih antarketiga titik injeksi menyusut hingga di bawah 1% selisih relatif satu sama lain nilai yang secara praktis berada dalam rentang kebisingan stokastik, bukan lagi perbedaan struktural yang bermakna. Pada $t=10$, ketiga simulasi konvergen ke cakupan hampir identik: T_1 = 7.112 node (99,6%), T_3 = 7.116 node (99,6%), T_8 = 7.108 node (99,5%). Temuan ini konsisten dengan diameter jejaring yang sangat kecil (4, Subbab 3.1.2): begitu proses difusi memasuki fase eksponensial, seluruh jejaring jenuh dalam hitungan langkah, sehingga keunggulan titik injeksi bersentralitas tinggi hanya benar-benar berpengaruh pada kecepatan penyebaran di fase-fase awal, bukan pada cakupan akhirnya.

4.2 Pengaruh Node Sentral terhadap Kecepatan Penyebaran

Dari hasil simulasi SI pada Subbab 4.1.2, hierarki pengaruh node terhadap kecepatan eksposur informasi pada jejaring MOOC dapat dirumuskan berdasarkan performa pada tahap awal difusi ($t=1$ dan $t=2$), sebelum jejaring memasuki fase saturasi serentak pada $t \geq 3$:

Peringkat	Node	Metrik Dominan	Node Terekspos pada t=1 / t=2	Catatan
1 (Tertinggi)	T_1	Degree + Betweenness + Closeness + Eigenvector	648 / 1.357	Tercepat; unggul konsisten di seluruh metrik sentralitas
2	T_3	Degree + Betweenness + Closeness + Eigenvector	600 / 1.265	Sedikit di bawah T_1; posisi peringkat 2 konsisten
3	T_4 / T_7	Degree + Closeness/Eigenvector	Tidak disimulasikan	Belum diuji langsung; posisi diprediksi di antara T_3 dan T_8 berdasarkan sentralitas
4 (Terendah dari Top- 5)	T_8	Degree + Betweenness + Closeness	482 / 1.017	Terlambat pada tahap awal, namun cakupan akhir (t=10) hampir identik dengan T_1 dan T_3

Tabel 4.2 Hierarki pengaruh node terhadap kecepatan eksposur informasi berdasarkan hasil simulasi SI empiris pada tahap awal difusi (t=1, t=2). Kolom kecepatan pada baris T_4/T_7 masih bersifat prediksi berdasarkan sentralitas karena belum diuji langsung melalui simulasi.

Temuan empiris ini memiliki implikasi praktis bagi pengelola platform MOOC. Jika platform ingin menyebarkan pengumuman penting, pembaruan kurikulum, atau konten promosi secara cepat pada fase-fase awal, menempatkan informasi tersebut pada aktivitas T_1 atau T_3 terbukti mempercepat jangkauan awal hingga 34% dibanding T_8 dalam dua langkah pertama. Namun demikian, keunggulan ini bersifat sementara: karena jejaring MOOC memiliki diameter yang sangat kecil (4), seluruh jejaring akan tersaturasi (>99%) dalam waktu sekitar 7–10 langkah terlepas dari titik awal penyebarannya. Implikasinya, pemilihan titik injeksi paling berpengaruh terutama untuk kebutuhan yang sensitif terhadap kecepatan (mis. peringatan darurat, pengumuman mendesak), namun kurang berpengaruh untuk konten yang tidak sensitif waktu, karena cakupan akhirnya akan hampir sama besar dari titik mana pun ia disebar. Untuk risiko penyebaran konten negatif (misinformasi, spam), temuan ini justru mengindikasikan bahwa moderasi hanya pada node dengan sentralitas tertinggi tidak cukup mencegah penyebaran menyeluruh menjelang $t=7$, konten negatif yang disuntikkan dari titik mana pun (termasuk titik bersentralitas rendah seperti T_8) tetap berpotensi menjangkau hampir seluruh jejaring.

Berdasarkan temuan konvergensi pada Subbab 4.1.2, strategi imunisasi berbasis sentralitas (centrality-based immunization) yang hanya menysasar node top-5 (T_1, T_3, T_4, T_7, T_8) kemungkinan tidak cukup efektif untuk mencegah penyebaran menyeluruh pada jejaring ini, mengingat

bahkan titik injeksi dengan sentralitas terendah di antara top-5 (T_8) tetap mencapai 99,5% cakupan jejaring pada $t=10$. Strategi yang lebih efektif kemungkinan memerlukan pembatasan langsung pada laju transmisi β (mis. melalui pembatasan akses/rate-limiting pada level platform) atau intervensi pada fase sangat awal ($t \leq 2$) sebelum lonjakan saturasi pada $t=3$ terjadi, alih-alih hanya mengandalkan pemfilteran node bersentralitas tinggi. Efektivitas strategi alternatif ini tetap memerlukan simulasi intervensi tersendiri yang berada di luar cakupan naskah ini.

4.3 Visualisasi Jejaring

4.3.1 Implementasi NetworkX Spring Layout

Visualisasi jejaring dihasilkan menggunakan NetworkX dengan algoritma tata letak `spring_layout`, yang mengimplementasikan algoritma Fruchterman-Reingold. Algoritma ini memodelkan jejaring seperti sistem pegas (spring): node-node yang terhubung saling tarik-menarik sedangkan node yang tidak terhubung saling tolak, hingga mencapai keseimbangan gaya yang menghasilkan posisi visual yang intuitif. Node-node yang banyak terhubung secara alami tertarik ke pusat, sedangkan node perifer dengan sedikit koneksi cenderung berada di tepi.

```
pos = nx.spring_layout(G_undirected, k=0.15, seed=42)

# Warna berdasarkan tipe node (bukan lagi komunitas Louvain)
node_colors = ["#e74c3c" if n.startswith("U_") else "#3498db"
               for n in G_undirected.nodes()]
```

```
# Ukuran node berdasarkan degree centrality
node_sizes = [degree_cent[node] * 2000
               for node in G_undirected.nodes()]

nx.draw_networkx_nodes(
    G_undirected, pos,
    node_size=node_sizes,
    node_color=node_colors, alpha=0.7
)
nx.draw_networkx_edges(
    G_undirected, pos,
    alpha=0.02, edge_color="gray"
)
plt.savefig("visualisasi_mooc_jejaring_v2.png", dpi=300)
```

Parameter kunci pada kode visualisasi:


- $k=0.15$: jarak ideal antar node pada algoritma Fruchterman-Reingold. Nilai yang lebih kecil membuat node lebih rapat dan cocok untuk jejaring besar.
- $seed=42$: memastikan hasil visualisasi bersifat deterministik dan dapat direproduksi.
- $alpha=0.02$ pada edge: transparansi tinggi pada edge diperlukan karena dengan 178.443 edge, tanpa transparansi seluruh area pusat akan tertutup garis abu-abu.
- $node_size = degree_cent * 2000$: mengkodekan Degree Centrality ke dalam ukuran visual node, sehingga node hub terlihat jelas lebih besar.
- $node_color$ berdasarkan tipe node: node bertipe pengguna diwarnai merah dan node bertipe target aktivitas diwarnai biru, menggantikan pewarnaan berbasis komunitas Louvain pada versi sebelumnya,

mengingat struktur komunitas yang terdeteksi pada Subbab 3.3 tergolong lemah (Modularity $Q = 0,0865$) dan kurang tepat dijadikan dasar pewarnaan visual utama.

4.3.2 Analisis Visual Hasil Visualisasi

Gambar di bawah menampilkan hasil visualisasi jejaring MOOC dengan 7.144 node dan 178.443 edge (graf terhubung penuh, terverifikasi bipartit) yang dihasilkan oleh skrip Python analisis_mooc_v2.py.

Visualisasi Jejaring MOOC (Bipartit)
Merah = User, Biru = Target Aktivitas | Ukuran = Degree Centrality



Gambar 4.1 Visualisasi jejaring MOOC menggunakan NetworkX spring_layout pada graf yang telah terkoreksi. Ukuran node merepresentasikan Degree Centrality; warna merah menandakan node pengguna dan warna biru menandakan node target aktivitas (bukan lagi pewarnaan berbasis komunitas Louvain seperti versi sebelumnya). Terlihat jelas struktur inti biru padat (97 target) yang dikelilingi oleh sebaran merah (7.047 pengguna) di sekeliling.

Dari visualisasi Gambar 4.1, karakteristik struktural jejaring bipartit terkonfirmasi secara visual: terdapat inti biru yang sangat padat di pusat, merepresentasikan 97 node target aktivitas dengan Degree Centrality tinggi, dikelilingi oleh sebaran radial node merah (7.047 pengguna) yang jauh lebih banyak jumlahnya namun masing-masing berkoneksi jauh lebih sedikit. Pola “bintang” (star-like) ini merupakan konsekuensi langsung dari rasio populasi node yang sangat timpang antara target dan pengguna, konsisten dengan temuan Density rendah (Subbab 3.1) dan Clustering Coefficient nol (Subbab 3.2). Berbeda dari versi analisis sebelumnya, naskah ini tidak lagi mengklaim pola visual tersebut sebagai indikasi distribusi degree power-law atau ciri jejaring scale-free (Barabási & Albert, 1999); pengujian statistik formal atas distribusi degree (mis. metode Clauset-Shalizi-Newman) tetap berada di luar cakupan visualisasi pada bab ini dan direkomendasikan sebagai pengembangan lanjutan apabila klaim tersebut ingin diajukan kembali secara sah.

BAB 5

Kesimpulan dan Tautan Proyek

5.1 Kesimpulan Karakteristik Jaringan

Pola interaksi 7.144 node (7.047 pengguna dan 97 target aktivitas) melalui 178.443 edge tergambarkan secara utuh dan terverifikasi berkat analisis komprehensif terhadap dataset ACT-MOOC menggunakan Python NetworkX. Sintesis dari seluruh temuan analisis tersebut, setelah koreksi metodologis atas skema pengindeksan ID (Subbab 5.2), disajikan berikut ini.

A. Representasi dan Jenis Graf

Setiap edge pada jejaring MOOC ini memodelkan aksi satu arah dari pengguna menuju target aktivitas, sehingga representasinya berbentuk graf berarah bipartit tidak berbobot (directed unweighted bipartite graph). Sifat bipartit ini telah diverifikasi secara eksplisit melalui `nx.bipartite.is_bipartite()` (True) dan dikonfirmasi lebih lanjut oleh Clustering Coefficient = 0 (Subbab 3.2). Sifat berarah tetap bersifat fundamental, sebab menunjukkan karakteristik asimetri yang inherent pada relasi belajar: pengguna yang mengakses konten, bukan sebaliknya.

B. Struktur Sentralitas dan Aktor Kunci

Distribusi pengaruh pada jejaring ini tampak sangat tidak merata berdasarkan hasil analisis sentralitas, namun dengan pola yang berbeda dari laporan sebelumnya: seluruh node top-5 pada keempat metrik sentralitas (Degree, Betweenness, Closeness, Eigenvector) ternyata bertipe TARGET, bukan USER (Subbab

2.2). T_1 mendominasi secara mutlak pada seluruh metrik sekaligus Degree Centrality (0,9373), Betweenness Centrality (0,1672), Closeness Centrality (0,8993), dan Eigenvector Centrality (0,1439) menjadikannya aktivitas paling banyak diakses dan paling sentral secara struktural di seluruh jejaring. T_3 secara konsisten menempati posisi kedua pada seluruh metrik. Temuan ini merupakan konsekuensi struktural dari rasio populasi node yang sangat timpang (97 target berbanding 7.047 pengguna), bukan indikasi adanya “pengguna super-hub” seperti yang sempat dilaporkan pada versi analisis sebelumnya.

C. Karakteristik Jarak-Pendek pada Graf Bipartit

Berdasarkan kombinasi metrik yang dianalisis, jejaring MOOC ini menunjukkan Density sangat rendah (0,003497), Average Clustering Coefficient bernilai nol (0,000000; sesuai teori graf bipartit murni, Subbab 3.2), Average Path Length rendah (2,0236), dan Diameter kecil (4) pada graf yang kini terhubung penuh. Klasifikasi Small-World Network versi klasik (Watts-Strogatz, 1998), yang mensyaratkan clustering tinggi berdampingan dengan APL rendah, tidak dapat diterapkan secara sah di sini karena $ACC = 0$ merupakan konsekuensi struktural bipartit yang berlaku pada graf bipartit acak mana pun, bukan properti pembeda jejaring MOOC. Yang tetap dapat dilaporkan secara sah adalah fenomena jarak pendek (short-path phenomenon) khas graf bipartit hub-dominan: jejaring ini renggang secara global namun tetap kompak dari sisi jarak antarnode.

D. Struktur Komunitas Modular

Tiga komunitas terdeteksi pada level pengguna melalui proyeksi graf user-user, dengan Modularity $Q = 0,0865$ yang tergolong rendah dan distribusi ukuran yang sangat timpang (4.471, 2.520, dan 56 pengguna). Struktur komunitas pada jejaring ini tergolong lemah, kemungkinan besar disebabkan oleh keterbatasan jumlah target aktivitas (97) yang membuat graf proyeksi nyaris menjadi graf lengkap (densitas $\sim 99,3\%$). Interpretasi kontekstual yang kaya atas makna tiap komunitas (mis. sebagai jalur belajar berbeda) tidak diajukan pada revisi ini karena kekuatan struktural yang mendasarinya belum memadai.

E. Implikasi Simulasi Difusi Informasi

Simulasi model SI dijalankan ulang pada graf terkoreksi dengan tiga titik injeksi target (T_1 , T_3 , T_8 ; $\beta=0,1$, 10 langkah). Hasilnya mengonfirmasi sebagian prediksi berbasis sentralitas sekaligus mengungkap batasannya: T_1 dan T_3 (peringkat 1 dan 2 pada seluruh metrik sentralitas) unggul signifikan pada tahap awal difusi hingga 34% lebih cepat dibanding T_8 pada $t=1-2$ namun keunggulan ini bersifat sementara. Mulai $t=3$, seluruh jejaring mengalami lonjakan eksposur serentak ($>79\%$ jejaring dalam satu langkah), dan pada $t=10$ ketiga titik injeksi konvergen ke cakupan yang hampir identik (99,5–99,6%). Temuan ini konsisten dengan diameter jejaring yang sangat kecil (4, Subbab 3.1.2): sentralitas node berpengaruh nyata terhadap kecepatan penyebaran informasi pada fase awal, namun tidak terhadap cakupan akhirnya, karena

struktur jejaring yang sangat kompak membuat hampir seluruh titik injeksi pada akhirnya menjangkau seluruh populasi.

Aspek Analisis	Temuan Utama	Implikasi
Jenis Graf	Berarah, Tidak Berbobot, Bipartit Terverifikasi	Aksi satu arah, non-simetris, edge hanya lintas himpunan user-target
Skala Jejaring	7.144 node, 178.443 edge	7.047 pengguna + 97 target; graf terhubung penuh
Density	0,003497 (sparse)	Hanya 0,35% edge yang terwujud
Clustering Coeff.	0,000000 (nol)	Sesuai teori graf bipartit murni; terverifikasi via <code>is_bipartite=True</code>
Avg. Path Length	2,0236	Jarak antar node tetap dekat meski density rendah
Diameter	4	Maks 4 langkah pada graf penuh (bukan lagi giant component)
Komunitas	3 komunitas (proyeksi user-user), $Q=0,0865$	Struktur komunitas lemah; interpretasi konten ditahan
Aktivitas Terdominan	T_1 (DC=0,9373)	Peringkat 1 di seluruh metrik sentralitas; aktivitas paling banyak diakses
Titik Injeksi Simulasi	T_1 tercepat pada tahap awal (648/1.357 node pada $t=1/t=2$)	Keunggulan T_1/T_3 atas T_8 hanya bermakna di $t \leq 2$; seluruh titik konvergen >99% pada $t=10$

Tipe Jejaring	Hub-Dominated Bipartite Network	Jarak pendek namun clustering=0 sesuai struktur bipartit; bukan Small-World klasik Watts-Strogatz
---------------	---------------------------------	---

Tabel 5.1 Ringkasan komprehensif seluruh temuan analisis jejaring MOOC.

5.2 Tautan Repository GitHub

Kode sumber, dataset (beserta instruksi pengunduhannya), dan hasil visualisasi dari keseluruhan proyek analisis jejaring sosial ini dapat diakses secara publik melalui repository GitHub berikut:

<https://github.com/yoozet/Analisis-Jejaring-Sosial-Ebook.git>

Repository ini berisi struktur direktori sebagai berikut:

```
Analisis-Jejaring-Sosial/
├── act-mooc/
│   └── mooc_actions.tsv          # Dataset (unduh dari SNAP
Stanford)
├── analisis_mooc_v2.py          # Skrip analisis utama
(versi terkoreksi)
├── visualisasi_mooc_jejaring_v2.png # Output visualisasi
(versi terkoreksi)
└── README.md                   # Panduan instalasi &
penggunaan
```

Dataset ACT-MOOC dapat diunduh secara bebas dari Stanford Network Analysis Project (SNAP) di alamat: <https://snap.stanford.edu/data/act-mooc.html>. Dataset ini berisi 411.749 aksi dari 7.047 pengguna terhadap 97 target aktivitas yang terekam selama periode tertentu; seluruh angka ini telah

diverifikasi langsung dan cocok dengan file `mooc_actions.tsv` yang digunakan pada analisis ini.

Perlu dicatat bahwa pada draf analisis awal, jumlah node dan edge yang terbentuk sempat tidak sesuai dengan deskripsi resmi dataset (7.047 pengguna, 97 target aktivitas) di atas. Verifikasi langsung terhadap berkas `mooc_actions.tsv` mengungkap dua penyebab: (1) baris header pada berkas TSV sempat ikut terbaca sebagai baris data karena parameter `skiprows` belum diterapkan, dan (2) seluruh 97 `TARGETID` pada dataset ternyata bertabrakan secara numerik dengan sebagian `USERID`, sehingga `NetworkX` menyatukan node pengguna dan node target yang kebetulan bernomor sama. Kedua masalah telah diperbaiki masing-masing melalui parameter `skiprows=1` pada pembacaan berkas, dan pemberian namespace terpisah (prefiks `U_` untuk pengguna, `T_` untuk target) sebelum graf dibentuk. Setelah perbaikan, jumlah node yang terbentuk ($7.144 = 7.047 \text{ pengguna} + 97 \text{ target}$) dan jumlah edge (178.443 pasangan unik) telah terverifikasi konsisten dengan deskripsi dataset resmi di atas, dan seluruh metrik pada Bab 1–5 pada revisi ini dihitung menggunakan graf yang telah dikoreksi tersebut.

Untuk menjalankan kode, pastikan dependensi Python berikut telah terpasang:

```
pip install networkx pandas matplotlib python-louvain numpy
```

DAFTAR PUSTAKA

Barabási, A. L., & Albert, R. (1999). Emergence of scaling in random networks. *Science*, 286(5439), 509–512. <https://doi.org/10.1126/science.286.5439.509>

Blondel, V. D., Guillaume, J. L., Lambiotte, R., & Lefebvre, E. (2008). Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, 2008(10), P10008. <https://doi.org/10.1088/1742-5468/2008/10/P10008>

Kumar, S., Zhang, X., & Leskovec, J. (2019). Predicting dynamic embedding trajectory in temporal interaction networks. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 1269–1278. <https://doi.org/10.1145/3292500.3330895>

Newman, M. E. J. (2010). *Networks: An introduction*. Oxford University Press.

Pastor-Satorras, R., & Vespignani, A. (2001). Epidemic spreading in scale-free networks. *Physical Review Letters*, 86(14), 3200–3203. <https://doi.org/10.1103/PhysRevLett.86.3200>

Poquet, O., Saqr, M., & Chen, B. (2021). Recommendations for network research in learning analytics: To open a conversation. Proceedings of the NetSciLA21 Workshop, Companion Proceedings of the 11th International Conference on Learning Analytics & Knowledge (LAK21).

Saqr, M., Elmoazen, R., Tedre, M., Lopez-Pernas, S., & Hirsto, L. (2022). How well centrality measures capture student achievement in computer-supported collaborative learning? A systematic review and meta-analysis. *Educational Research Review*, 35, 100437. <https://doi.org/10.1016/j.edurev.2022.100437>

Saqr, M., & Lopez-Pernas, S. (2022). The curious case of centrality measures: A large-scale empirical investigation. *Journal of Learning Analytics*, 9(3), 13–31.

Setatama, M. S., & Tricahyono, D. (2017). Implementasi Social Network Analysis pada Penyebaran Country Branding “Wonderful Indonesia”. *Indonesian Journal on Computing (Indo-JC)*, 2(2), 91–102.

Soleymani, A., Itard, L., de Laat, M., Valle Torre, M., & Specht, M. (2022). Using social network analysis to explore learning networks in MOOCs discussion forums. Proceedings of the

<https://doi.org/10.34641/clima.2022.300>

Susanto, B., Lina, H., & Chrismanto, A. R. (2012). Penerapan Social Network Analysis dalam Penentuan Centrality: Studi Kasus Social Network Twitter. *Jurnal Informatika*, 8(1). <https://doi.org/10.21460/inf.2012.81.111>

Watts, D. J., & Strogatz, S. H. (1998). Collective dynamics of 'small-world' networks. *Nature*, 393(6684), 440–442. <https://doi.org/10.1038/30918>

Wu, B., & Wu, C. (2021). Research on the mechanism of knowledge diffusion in the MOOC learning forum using ERGMs. *Computers & Education*, 173, 104295. <https://doi.org/10.1016/j.compedu.2021.104295>

Yen, T.-C., & Larremore, D. B. (2020). Community detection in bipartite networks with stochastic block models. *Physical Review E*, 102(3), 032309. <https://doi.org/10.1103/PhysRevE.102.032309>

Zou, W., Hu, X., Pan, Z., Li, C., Cai, Y., & Liu, M. (2021). Exploring the relationship between social presence and learners' prestige in MOOC discussion forums using automated content

analysis and social network analysis. Computers in Human Behavior, 115, 106582.
<https://doi.org/10.1016/j.chb.2020.106582>

SINOPSIS

Social Network Analysis: Analisis Jejaring Sosial MOOC membahas penerapan konsep Social Network Analysis (SNA) dalam menganalisis pola interaksi pada Massive Open Online Course (MOOC) menggunakan dataset ACT-MOOC dari Stanford SNAP. Pembahasan mencakup proses pembentukan graf, analisis karakteristik jejaring, pengukuran sentralitas aktor, deteksi komunitas menggunakan algoritma Louvain, serta simulasi difusi informasi menggunakan model Susceptible-Infected (SI). Seluruh analisis dilakukan menggunakan Python dan NetworkX dengan pendekatan berbasis data untuk memahami struktur jejaring, peran aktor, dan dinamika penyebaran informasi dalam lingkungan pembelajaran daring. Buku ini disusun sebagai bahan ajar dan referensi praktis bagi mahasiswa, dosen, dan peneliti yang mempelajari Social Network Analysis, Graph Mining, dan Data Science.

Topik yang Dibahas

- Representasi Graf dan Dataset ACT-MOOC
- Analisis Karakteristik Jejaring Sosial
- Degree, Betweenness, Closeness, dan Eigenvector Centrality
- Community Detection dengan Algoritma Louvain
- Simulasi Difusi Informasi menggunakan Model SI
- Visualisasi Jejaring Menggunakan Python dan NetworkX

Kata Kunci

Social Network Analysis • Graph Theory • Graph Mining • Data Science • NetworkX • Community Detection • Centrality Analysis • Information Diffusion • MOOC • Stanford SNAP

